

P04-SIA: Desain dan Implementasi Analitik Data Prediktif (Data Mining)



Dosen Pengampu:

Ir. Nanang Yudi Setiawan, S.T., M.Kom

Disusun oleh:

1. Dzaki Althalsyah (245150407111071)
2. Dhea Akmalia Fibri (245150407111081)
3. Muhammad Rifa Aqilla (245150407111047)
4. Fairuz El Fauzy (245150407111032)

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS BRAWIJAYA

2026

1. Pendahuluan

Industri telekomunikasi memiliki tantangan utama dalam mempertahankan pelanggan karena churn berdampak langsung pada pendapatan dan biaya akuisisi pelanggan baru. Oleh karena itu, proyek ini berfokus pada pembangunan model prediktif untuk mengidentifikasi pelanggan yang berisiko churn berdasarkan data historis penggunaan layanan, pendapatan, kualitas panggilan, dan profil pelanggan.

Tujuan utama analisis ini adalah menghasilkan model machine learning yang dapat memprediksi probabilitas churn pelanggan, membandingkan beberapa algoritma klasifikasi, memilih model terbaik berdasarkan metrik evaluasi yang sesuai, serta mengintegrasikan hasil prediksi ke dashboard bisnis. Dashboard final digunakan untuk menampilkan ringkasan churn pelanggan dan insight prediktif agar hasil analitik dapat langsung mendukung keputusan retensi.

1.1 Latar Belakang Bisnis

Industri telekomunikasi menghadapi tekanan persaingan yang tinggi, di mana perpindahan pelanggan ke kompetitor (churn) menjadi ancaman utama bagi keberlangsungan pendapatan perusahaan. Biaya untuk memperoleh pelanggan baru diperkirakan lima hingga tujuh kali lebih mahal dibandingkan biaya mempertahankan pelanggan yang sudah ada. Oleh karena itu, kemampuan untuk mengidentifikasi pelanggan yang berpotensi churn sebelum mereka benar-benar berhenti berlangganan memiliki nilai strategis yang sangat tinggi bagi perusahaan telekomunikasi.

Proyek ini menggunakan pendekatan analitik prediktif berbasis machine learning untuk membangun model yang mampu mengestimasi probabilitas churn setiap pelanggan. Dengan memanfaatkan data historis penggunaan layanan, pendapatan, kualitas panggilan, dan profil pelanggan, model dapat digunakan sebagai alat bantu pengambilan keputusan dalam program retensi pelanggan yang lebih terarah dan efisien.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah yang diangkat dalam proyek ini adalah: (1) Algoritma machine learning mana yang paling optimal untuk memprediksi churn pelanggan telekomunikasi berdasarkan data historis yang tersedia? (2) Fitur atau variabel apa saja yang paling berpengaruh terhadap kemungkinan churn pelanggan? (3) Bagaimana hasil

prediksi model dapat diintegrasikan ke dalam dashboard bisnis sehingga dapat langsung digunakan untuk mendukung pengambilan keputusan retensi?

1.3 Tujuan Proyek

Tujuan utama proyek ini adalah membangun pipeline machine learning yang lengkap mulai dari pemahaman data hingga deployment hasil prediksi. Secara spesifik, tujuan proyek mencakup: (1) Membangun dan membandingkan beberapa model klasifikasi untuk memprediksi churn pelanggan dengan metrik evaluasi yang relevan; (2) Melakukan preprocessing data secara mendalam untuk memastikan kualitas input model; (3) Memilih model terbaik berdasarkan kombinasi metrik accuracy, precision, recall, F1-score, ROC-AUC, dan PR-AUC sesuai konteks bisnis; serta (4) Mengintegrasikan hasil prediksi model ke dalam dashboard interaktif yang dapat digunakan langsung oleh tim bisnis untuk perencanaan retensi pelanggan.

1.4 Kriteria Keberhasilan

Proyek ini dianggap berhasil apabila memenuhi kriteria berikut: model prediksi mencapai ROC-AUC minimal 0,65 pada test set, precision prediksi churn mencapai minimal 0,65 dengan strategi threshold yang dipilih, hasil prediksi berhasil diintegrasikan ke dashboard dalam bentuk visualisasi yang dapat langsung mendukung keputusan retensi, dan seluruh artefak model (preprocessor, selector, model bundle, threshold, serta churn scores) tersimpan dan dapat direproduksi untuk keperluan deployment.

1.5 Metodologi

Proyek ini menggunakan metodologi CRISP-DM (Cross-Industry Standard Process for Data Mining) sebagai kerangka kerja. CRISP-DM dipilih karena menyediakan alur kerja yang terstruktur dan iteratif, mulai dari pemahaman bisnis hingga deployment, yang sesuai dengan kebutuhan proyek analitik prediktif berbasis data tabular. Tahapan CRISP-DM yang diterapkan meliputi Business Understanding (Bab 1), Data Understanding (Bab 3), Data Preparation (Bab 4), Modeling (Bab 5), Evaluation (Bab 6), dan Deployment (Bab 7 dan 8).

2. Ketepatan Pemilihan Teknik Mining

Teknik mining yang digunakan adalah data mining berbasis supervised classification. Pemilihan teknik ini sesuai dengan karakteristik studi kasus karena target yang diprediksi adalah churn, yaitu label biner yang menunjukkan apakah pelanggan berhenti menggunakan

layanan atau tidak. Data yang digunakan juga berbentuk tabular terstruktur dengan kombinasi fitur numerik dan kategorikal, bukan data teks, web log, maupun process event log.

Pendekatan klasifikasi mampu menjawab problem prediktif secara langsung: dari atribut pelanggan, model menghasilkan probabilitas churn dan label risiko. Output ini dapat dipakai oleh tim bisnis untuk melakukan tindakan retensi secara lebih terarah. Dengan demikian, teknik mining yang dipilih sinkron dengan struktur data dan tujuan bisnis.

Aspek	Kondisi Data/Problem	Implikasi Terbaik
Target	Churn bernilai biner 0/1	Menggunakan supervised classification
Struktur data	100.000 baris dan 100 kolom awal; numerik + kategorikal	Cocok untuk data mining tabular
Tujuan bisnis	Mengidentifikasi pelanggan berisiko churn	Model menghasilkan probabilitas churn dan prioritas intervensi
Teknik yang tidak dipilih	Text/Web/Process mining	Tidak relevan karena data bukan dokumen teks, web crawl, atau event log proses

3. Data Understanding

Dataset awal terdiri dari 100.000 data pelanggan dengan 100 kolom. Fitur yang tersedia mencakup revenue, usage, call quality, histori penggunaan, device/profile, serta target churn. Data juga memiliki missing value pada beberapa kolom, terutama kolom profil pelanggan, sehingga membutuhkan tahap pembersihan dan transformasi sebelum dimasukkan ke model.

Distribusi target pada data training relatif seimbang, yaitu 32.280 pelanggan tidak churn dan 31.720 pelanggan churn. Kondisi ini penting karena model tidak perlu dipaksa menggunakan teknik oversampling seperti SMOTE. Fokus preprocessing diarahkan pada penanganan missing value, outlier, encoding fitur kategorikal, scaling fitur numerik, dan pencegahan data leakage.

3.1 Struktur dan Dimensi Data

Dataset yang digunakan dalam proyek ini adalah data pelanggan telekomunikasi yang terdiri dari 100.000 baris dan 100 kolom. Setiap baris merepresentasikan satu pelanggan dengan fitur-fitur yang mencakup berbagai aspek penggunaan layanan. Kolom-kolom tersebut dapat dikelompokkan ke dalam beberapa kategori, yaitu fitur revenue (pendapatan dan tagihan), fitur usage (penggunaan layanan suara dan data), fitur call quality (kualitas panggilan seperti attempt, completion, dan drop rate), fitur histori penggunaan (rata-rata bulanan dan perubahan tren), fitur device dan profil pelanggan, serta kolom target churn bernilai biner 0 (tidak churn) dan 1 (churn).

3.2 Kualitas Data dan Missing Value

Pemeriksaan missing value pada dataset menunjukkan bahwa sebagian besar kolom memiliki data yang lengkap, namun beberapa kolom profil pelanggan memiliki tingkat missing value yang cukup tinggi sehingga perlu ditangani sebelum pemodelan. Kolom-kolom dengan missing value tinggi seperti numbcars, ownrent, dwlltype, dwllsize, HHstatin, lor, adults, income, infobase, hnd_webcap, dan prizm_social_one diputuskan untuk dihapus dari analisis karena kualitas datanya tidak stabil dan kontribusinya terhadap prediksi churn diperkirakan rendah. Kolom-kolom numerik dan kategorikal lainnya yang memiliki missing value moderat ditangani melalui teknik imputasi pada tahap preprocessing.

3.3 Distribusi Target dan Keseimbangan Kelas

Analisis distribusi target menunjukkan bahwa dataset memiliki komposisi kelas yang relatif seimbang. Dari total 80.000 data training (sebelum split validation), terdapat 32.280 pelanggan yang tidak churn (label 0) dan 31.720 pelanggan yang churn (label 1), dengan rasio sekitar 50,4% berbanding 49,6%. Keseimbangan kelas ini merupakan kondisi yang menguntungkan karena model tidak akan bias secara sistematis ke salah satu kelas. Dengan kondisi ini, teknik oversampling seperti SMOTE tidak diperlukan, dan model dapat dilatih langsung pada distribusi data asli tanpa risiko overfitting terhadap kelas minoritas.

3.4 Eksplorasi Korelasi Fitur terhadap Target

Analisis korelasi dilakukan hanya pada data training untuk menghindari data leakage dari validation dan test set. Fitur kategorikal dikonversi sementara ke kode numerik menggunakan label encoding untuk keperluan perhitungan korelasi. Hasil analisis menunjukkan bahwa fitur-fitur yang berkaitan dengan pendapatan dan penggunaan layanan memiliki korelasi yang

lebih tinggi terhadap target churn dibandingkan fitur profil demografis pelanggan. Fitur-fitur seperti perubahan revenue (change_rev), rata-rata revenue (rev_Mean, avgrev), total revenue (totrev), serta fitur-fitur penggunaan menit (mou_Mean, totmou) termasuk dalam kelompok yang memiliki korelasi absolut tertinggi terhadap churn. Temuan ini mengonfirmasi bahwa perilaku penggunaan layanan dan pola pendapatan merupakan sinyal penting untuk memprediksi churn pelanggan.

3.5 Tipe Data dan Pemilihan Pendekatan Analitik

Dataset terdiri dari campuran fitur numerik kontinu, fitur numerik diskret, dan fitur kategorikal. Dari total 100 kolom awal, terdapat lebih banyak fitur numerik dibandingkan kategorikal. Karakteristik data tabular terstruktur dengan target biner ini sangat sesuai dengan pendekatan supervised classification dalam data mining. Pendekatan ini dipilih karena mampu memanfaatkan seluruh fitur numerik dan kategorikal secara bersamaan, menghasilkan probabilitas churn yang dapat diinterpretasikan, dan memungkinkan perbandingan antar algoritma secara sistematis untuk menemukan model dengan performa terbaik.

4. Kualitas Pre-processing Data

4.1 Data Cleaning Awal

Kolom Customer_ID dihapus dari data training karena hanya berfungsi sebagai identitas unik pelanggan. Kolom identifier tidak merepresentasikan perilaku pelanggan dan dapat membuat model menghafal pola ID, bukan mempelajari faktor churn yang sebenarnya.

Beberapa kolom lain seperti numbcars, ownrent, dwlltype, dwllsize, HHstatin, lor, adults, income, infobase, hnd_webcap, dan prizm_social_one dihapus karena memiliki kualitas data yang kurang stabil atau missing value tinggi. Penghapusan ini dilakukan untuk mengurangi noise dan mencegah model terlalu bergantung pada fitur yang tidak lengkap.

4.2 Feature Engineering

Feature engineering dilakukan untuk membentuk indikator perilaku pelanggan yang lebih informatif dibandingkan fitur mentah. Fitur completion_rate dibuat untuk menggambarkan keberhasilan panggilan, drop_rate untuk menggambarkan proporsi panggilan terputus, rev_per_mou untuk melihat pendapatan per menit penggunaan, serta rev_change_pct dan mou_change_pct untuk menangkap perubahan relatif pendapatan dan pemakaian.

Fitur numerik yang cenderung skewed seperti `rev_Mean`, `mou_Mean`, `totrev`, `totmou`, `adjrev`, `adjmou`, `avgrev`, `avgmou`, `avg3rev`, dan `avg6rev` ditransformasi menggunakan `log1p`. Selain itu, fitur overage seperti `ovrmou_Mean`, `vceovr_Mean`, `ovrrev_Mean`, dan `datovr_Mean` dibuat menjadi flag dan log agar model dapat menangkap baik keberadaan overage maupun besarnya nilai overage.

4.3 Split Data dan Pencegahan Data Leakage

Data dibagi menjadi train, validation, dan test set menggunakan stratified split. Jumlah data setelah pembagian adalah 64.000 data train, 16.000 data validation, dan 20.000 data test. Pembagian dilakukan sebelum preprocessing utama agar statistik preprocessing hanya dipelajari dari data train, sehingga menghindari data leakage.

4.4 Imputasi, Capping, Scaling, dan Encoding

Preprocessing diterapkan menggunakan pipeline agar proses transformasi konsisten antara training, evaluasi, dan deployment. Fitur numerik diproses dengan median imputation, quantile capping pada persentil 0,5% dan 99,5%, kemudian `StandardScaler`. Fitur kategorikal diproses dengan most frequent imputation dan `OneHotEncoder(handle_unknown="ignore")`.

Quantile capping digunakan untuk membatasi pengaruh outlier ekstrem tanpa menghapus data pelanggan. Capping dilakukan secara train-only melalui pipeline, sehingga batas bawah dan atas outlier dipelajari hanya dari data training. Setelah preprocessing, jumlah fitur menjadi 210 fitur, kemudian feature selection berbasis `LightGBM` menurunkannya menjadi 105 fitur terpilih.

SMOTE tidak digunakan karena target training relatif seimbang. Jika SMOTE dipaksakan pada data yang sudah seimbang, model dapat menjadi terlalu agresif memprediksi churn dan menghasilkan precision yang lebih rendah. Keputusan ini membuat training lebih sesuai dengan distribusi data asli.

Tahap Preprocessing	Teknik	Alasan
Drop identifier	Menghapus <code>Customer_ID</code>	Menghindari model menghafal identitas pelanggan
Drop kolom kualitas rendah	Menghapus kolom missing tinggi/noisy	Mengurangi noise input model

Missing value numerik	Median imputation	Lebih robust terhadap outlier
Missing value kategorikal	Most frequent imputation	Menjaga kategori dominan tetap konsisten
Outlier handling	Quantile capping P0.5-P99.5	Membatasi nilai ekstrim tanpa menghapus observasi
Scalling	StandardScaler	Menstabilkan skala fitur numerik
Encoding	OneHotEncoder	Menghindari asumsi urutan palsu pada kategori
Feature selection	SelectFromModel LightGBM threshold median	Mengurangi fitur dari 210 menjadi 105 fitur.

5. Pengembangan dan Eksperimen Model

Eksperimen model dilakukan secara bertahap. Logistic Regression digunakan sebagai baseline sederhana, Random Forest digunakan sebagai model ensemble berbasis bagging, sedangkan XGBoost, LightGBM, dan CatBoost digunakan karena kuat untuk data tabular dan mampu menangkap pola non-linear. Selain itu, dilakukan tuning pada XGBoost menggunakan Optuna dan dibuat Stacking Ensemble untuk menggabungkan kekuatan beberapa model terbaik.

LightGBM juga digunakan dengan early stopping pada validation set agar jumlah iterasi tidak berlebihan. Threshold prediksi tidak hanya menggunakan default 0,5, tetapi diuji dengan beberapa strategi: default_0_5, max_f1, dan min_precision. Strategi final diarahkan ke min_precision dengan target precision 0,65 agar prediksi churn lebih selektif dan tidak terlalu banyak false positive.

Hyperparameter tuning XGBoost dilakukan dengan 30 trials, 3-fold StratifiedKFold, dan objective average_precision. Best CV average precision yang diperoleh adalah sekitar 0,6876 dengan parameter terbaik antara lain n_estimators 591, max_depth 5, learning_rate 0,0363, subsample 0,9336, colsample_bytree 0,8964, min_child_weight 4, dan reg_lambda 5,7223.

Model	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
-------	----------	-----------	--------	----	---------	--------

Stacking Ensemble	0,64095	0,64597	0,60967	0,62729	0,69955	0,69193
CatBoost	0,64005	0,64853	0,59756	0,62200	0,69609	0,68809
LightGBM	0,63970	0,64269	0,61481	0,62844	0,69774	0,69075
XGBoost Tuned	0,63920	0,64665	0,59968	0,62228	0,69812	0,69068
XGBoost	0,63840	0,64575	0,59897	0,62148	0,69671	0,68962
Random Forest	0,61670	0,63888	0,52119	0,57406	0,67425	0,66389
Logistic Regression	0,58085	0,64819	0,33737	0,44377	0,63982	0,62516

Hasil eksperimen menunjukkan bahwa Logistic Regression memiliki performa paling rendah, terutama pada recall dan F1-score. Hal ini menunjukkan bahwa pola churn tidak cukup dijelaskan oleh hubungan linear sederhana. Random Forest meningkat dibanding baseline, tetapi masih kalah dari boosting model. Model boosting memberikan performa lebih stabil dengan ROC-AUC mendekati 0,70.

Stacking Ensemble memperoleh accuracy, ROC-AUC, dan PR-AUC tertinggi secara keseluruhan. LightGBM memiliki F1-score sedikit lebih tinggi dibanding Stacking pada threshold final, tetapi selisihnya kecil. Oleh karena itu, Stacking Ensemble dipilih sebagai kandidat model final karena performa agregatnya paling kuat dan stabil.

6. Evaluasi dan Interpretasi Model

Evaluasi menggunakan accuracy, precision, recall, F1-score, ROC-AUC, dan PR-AUC. Accuracy menunjukkan proporsi prediksi benar secara umum. Precision menunjukkan ketepatan prediksi churn; semakin tinggi precision, semakin sedikit pelanggan yang salah ditandai sebagai churn. Recall menunjukkan kemampuan model menangkap pelanggan yang

benar-benar churn. F1-score menyeimbangkan precision dan recall. ROC-AUC dan PR-AUC mengevaluasi kemampuan model dalam membedakan dan memberi ranking risiko pelanggan.

Dalam konteks bisnis churn, precision dan recall perlu ditafsirkan bersama. Precision penting jika biaya program retensi cukup mahal, karena perusahaan ingin menarget pelanggan yang benar-benar berisiko. Recall penting jika perusahaan ingin meminimalkan pelanggan churn yang tidak terdeteksi. Karena proyek ini menggunakan strategi min_precision 0,65, model diarahkan agar prediksi churn lebih selektif.

Strategic Threshold Stacking	Threshold	Accuracy	Precision	Recall	F1	Interpretasi
default_0_5	0,5000	0,6454	0,6424	0,6421	0,6422	Threshold standar, cukup seimbang tetapi belum disesuaikan tujuan bisnis
max_f1	0,3373	0,6076	0,5662	0,8905	0,6923	Menangkap lebih banyak churn, tetapi banyak false positive
min_precision_0.65	0,5153	0,6447	0,6500	0,6134	0,6312	Lebih selektif; cocok jika biaya intervensi retensi perlu dikontrol

Interpretasi Bisnis Mendalam dari Metrik Evaluasi

Precision model Stacking Ensemble sebesar 0,646 memiliki makna bisnis yang konkret: dari setiap 100 pelanggan yang diprediksi akan churn oleh model, sekitar 64 hingga 65 pelanggan memang benar-benar akan churn, sedangkan sekitar 35 hingga 36 pelanggan adalah false positive, yaitu pelanggan yang sebenarnya tidak churn namun ikut tertandai. Dalam konteks retensi, false positive berarti perusahaan akan mengeluarkan biaya intervensi yang tidak perlu untuk pelanggan tersebut. Dengan precision 0,646, setidaknya dua pertiga dari anggaran retensi diarahkan ke pelanggan yang tepat.

Recall sebesar 0,610 berarti model berhasil mendeteksi sekitar 61% dari seluruh pelanggan yang benar-benar akan churn. Sekitar 39% pelanggan churn lainnya tidak terdeteksi oleh model (false negative). Dalam konteks bisnis, false negative berarti perusahaan kehilangan kesempatan untuk mempertahankan pelanggan yang seharusnya bisa diselamatkan melalui program retensi. Besarnya dampak false negative bergantung pada Average Revenue Per User (ARPU) dan biaya akuisisi pelanggan baru. Semakin tinggi ARPU dan biaya akuisisi, semakin mahal setiap false negative yang terjadi.

ROC-AUC sebesar 0,700 menunjukkan bahwa model memiliki kemampuan 70% lebih baik dibandingkan prediksi acak dalam membedakan pelanggan yang akan churn dan yang tidak. Dalam praktik bisnis, ini berarti jika perusahaan mengambil dua pelanggan secara acak — satu yang churn dan satu yang tidak — model akan memberikan skor risiko yang lebih tinggi kepada pelanggan churn sebanyak 70% dari kasus. Kemampuan ranking ini sangat berguna ketika perusahaan memiliki anggaran retensi terbatas dan perlu memprioritaskan siapa yang dihubungi terlebih dahulu.

PR-AUC sebesar 0,692 melengkapi interpretasi ROC-AUC dengan fokus pada kelompok pelanggan berisiko. PR-AUC lebih relevan ketika distribusi kelas cukup seimbang namun fokus utama adalah performa pada kelas positif (churn). Nilai 0,692 menunjukkan bahwa model cukup andal dalam memberi ranking pelanggan churn di posisi atas daftar prioritas, meskipun belum sempurna.

Implikasi Confusion Matrix dan Biaya Kesalahan

Dalam prediksi churn, terdapat dua jenis kesalahan yang memiliki biaya berbeda bagi perusahaan. False positive terjadi ketika model memprediksi pelanggan akan churn, padahal sebenarnya tidak. Biaya yang ditanggung adalah biaya program retensi yang dikeluarkan secara tidak perlu, seperti diskon, penawaran khusus, atau waktu customer service yang

terbuang. False negative terjadi ketika model gagal mendeteksi pelanggan yang sebenarnya akan churn. Biaya yang ditanggung adalah kehilangan pendapatan jangka panjang dari pelanggan tersebut, ditambah biaya akuisisi pelanggan baru untuk menggantinya.

Pemilihan strategi threshold `min_precision` 0,65 pada model ini secara implisit merupakan keputusan bisnis untuk memprioritaskan pengurangan false positive. Dengan threshold yang lebih tinggi, model hanya menandai pelanggan sebagai churn ketika tingkat keyakinannya cukup kuat, sehingga anggaran retensi lebih efisien. Pendekatan ini cocok ketika biaya program retensi per pelanggan cukup signifikan dan perusahaan tidak ingin menghamburkan sumber daya untuk pelanggan yang sebenarnya loyal.

Segmentasi Risiko dan Estimasi Dampak Finansial

Hasil scoring terhadap 100.000 pelanggan menghasilkan distribusi risiko yang dapat digunakan langsung untuk perencanaan anggaran retensi. Sebanyak 4.843 pelanggan memiliki churn score minimal 0,80 dan dikategorikan sebagai very high-risk. Kelompok ini sebaiknya menjadi prioritas utama untuk intervensi personal dan bernilai tinggi. Sebanyak 14.303 pelanggan memiliki churn score minimal 0,70 dan dikategorikan sebagai high-risk, cocok untuk program retensi terstruktur seperti penawaran paket khusus atau follow-up proaktif. Sebanyak 32.659 pelanggan berada pada rentang skor 0,50 hingga 0,70 dan dikategorikan sebagai medium-risk, yang dapat dimonitor melalui dashboard dan diberikan kampanye digital ringan. Pelanggan dengan skor di bawah 0,50 sebanyak 53.038 pelanggan dikategorikan sebagai low-risk dan tidak memerlukan intervensi aktif dalam jangka pendek.

Dengan menggunakan rata-rata pendapatan pelanggan (ARPU) sebesar 57,91 per periode sebagai acuan, potensi kehilangan pendapatan dari kelompok very high-risk mencapai sekitar $4.843 \times 57,91 \approx 280.500$ unit per periode jika tidak ada intervensi. Jika program retensi berhasil mempertahankan 30% dari kelompok ini, potensi pendapatan yang diselamatkan mencapai sekitar 84.000 unit per periode. Perhitungan ini menunjukkan bahwa bahkan program retensi dengan biaya moderat pun dapat memberikan return on investment yang positif jika diarahkan ke segmen yang tepat berdasarkan output model.

Indikator Scoring	Nilai	Makna Bisnis
Total pelanggan yang discoring	100.000	Seluruh pelanggan memiliki probabilitas churn
Rata-rata churn score	0,4962	Risiko rata-rata mendekati batas keputusan
Label churn pada CSV default	49.945 pelanggan (49,95%)	Label dari prediksi default model
Score $\geq$ threshold final 0,5153	46.962 pelanggan (46,96%)	Kandidat intervensi sesuai strategi min_precision
Score $\geq$ 0,70	14.303 pelanggan (14,30%)	Kelompok high-risk untuk prioritas retensi
Score $\geq$ 0,80	4.843 pelanggan (4,84%)	Kelompok very high-risk dengan prioritas tertinggi

Rekomendasi bisnis dari hasil model adalah membagi pelanggan ke dalam beberapa tier risiko. Pelanggan dengan score sangat tinggi dapat diprioritaskan untuk intervensi personal seperti follow-up customer service, penawaran paket khusus, atau evaluasi kualitas layanan. Pelanggan dengan risiko menengah dapat dimonitor melalui dashboard dan diberikan kampanye retensi yang lebih ringan. Pendekatan ini membuat biaya retensi lebih efisien karena tidak semua pelanggan diperlakukan sama.

7. Integrasi Insight ke Dashboard

Insight dari hasil analisis dan model prediksi churn telah diintegrasikan ke dalam dashboard interaktif. Dashboard ini dibuat untuk membantu pengguna memahami kondisi churn pelanggan secara deskriptif sekaligus melihat hasil analitik prediktif dari model machine learning. Dashboard terdiri dari dua tab utama, yaitu Ringkasan Churn Pelanggan dan Prediksi Churn Pelanggan.

Tab Ringkasan Churn Pelanggan berfokus pada analisis deskriptif dari kondisi pelanggan secara keseluruhan. Pada tab ini ditampilkan KPI utama seperti Total Churn Rate sebesar 49,56%, Total Pelanggan sebanyak 100.000, Total Churn sebanyak 49.562 pelanggan, serta rata-rata pendapatan pelanggan atau ARPU sebesar 57,91. Selain itu, dashboard juga menampilkan komposisi segmen pelanggan, distribusi tingkat risiko churn, ringkasan churn dalam bentuk tabel, serta tren churn rate berdasarkan lama berlangganan.

Visualisasi pada tab ringkasan membantu pengguna melihat kondisi aktual churn pelanggan. Diagram komposisi segmen menunjukkan bahwa pelanggan dengan status churned memiliki proporsi paling besar, yaitu sekitar 49,56%, diikuti oleh pelanggan stable, watch, at-risk, dan high value. Grafik distribusi risiko churn juga menunjukkan pembagian pelanggan ke dalam kategori Low, Medium, dan High, sehingga perusahaan dapat memahami kelompok pelanggan yang perlu dimonitor atau diprioritaskan untuk strategi retensi. Tren churn berdasarkan lama berlangganan digunakan untuk melihat pola perubahan churn rate pada pelanggan dengan durasi berlangganan yang berbeda.

Tab Prediksi Churn Pelanggan digunakan untuk menampilkan hasil analitik prediktif dari model churn. Tab ini menampilkan KPI seperti Potensi Pendapatan Hilang dari pelanggan High Risk sebesar \$849.763 dan Total Pelanggan Risiko Tinggi sebanyak 14.231 pelanggan. Informasi ini penting karena tidak hanya menunjukkan jumlah pelanggan yang berisiko, tetapi juga menghubungkannya dengan potensi dampak finansial terhadap perusahaan.

Pada tab prediktif, hasil model ditampilkan melalui beberapa visualisasi. Donut chart Churn Label menunjukkan perbandingan pelanggan dengan label churn 0 dan 1, yaitu sekitar 49% pelanggan tidak diprediksi churn dan 51% pelanggan diprediksi churn. Grafik rata-rata pendapatan berdasarkan prediksi churn label menunjukkan bahwa pelanggan dengan label 0 memiliki rata-rata pendapatan lebih tinggi, yaitu sekitar 84,1k, sedangkan pelanggan dengan label 1 memiliki rata-rata pendapatan sekitar 49,5k. Hal ini menunjukkan bahwa pelanggan yang diprediksi churn cenderung memiliki rata-rata pendapatan yang lebih rendah.

Dashboard prediktif juga menampilkan hubungan antara churn score dan rata-rata pendapatan. Dari visualisasi tersebut, churn score berada pada kisaran yang berbeda untuk tiap kelompok pendapatan, dengan kenaikan risiko pada beberapa rentang pendapatan tertentu. Selain itu, grafik tren risiko churn berdasarkan lama berlangganan menunjukkan bahwa risiko churn cenderung lebih tinggi pada kelompok pelanggan dengan lama berlangganan awal hingga menengah, kemudian menurun pada kelompok pelanggan dengan

masa berlangganan yang lebih panjang. Visualisasi dampak panggilan customer service terhadap risiko churn juga menunjukkan bahwa semakin tinggi rata-rata interaksi customer service, nilai churn score cenderung mengalami penurunan.

Integrasi dashboard dilakukan dengan memanfaatkan hasil scoring model yang telah disiapkan dalam file `churn_scores.csv`. File tersebut berisi informasi seperti `Customer_ID`, `ml_churn_score`, dan `ml_churn_label`, sehingga dapat digabungkan dengan data pelanggan menggunakan `Customer_ID`. Selain itu, artefak model seperti `thresholds.json`, `preprocessor.joblib`, `selector.joblib`, `stack_model.joblib`, dan `best_model.joblib` disiapkan untuk memastikan proses prediksi dapat direproduksi dan hasil dashboard konsisten dengan pipeline model yang telah dibangun.

Secara bisnis, dashboard ini mendukung proses pengambilan keputusan dalam strategi retensi pelanggan. Tab ringkasan membantu perusahaan memahami kondisi churn historis dan segmentasi pelanggan, sedangkan tab prediksi membantu perusahaan menentukan prioritas pelanggan yang perlu ditangani lebih dahulu. Pelanggan dengan risiko tinggi dapat menjadi target utama untuk tindakan retensi seperti follow-up customer service, pemberian penawaran khusus, evaluasi kualitas layanan, atau kampanye loyalitas. Dengan demikian, dashboard tidak hanya berfungsi sebagai alat visualisasi, tetapi juga sebagai media pendukung keputusan berbasis data.

Alur Data dari Model ke Dashboard

Integrasi antara pipeline machine learning dan dashboard dilakukan melalui mekanisme file artefak yang telah disiapkan sebelumnya. Alur data dimulai dari tahap scoring, di mana seluruh 100.000 data pelanggan diproses menggunakan bundle model (`best_model.joblib`) yang sudah menyimpan preprocessor, selector, model Stacking Ensemble, dan threshold final. Output scoring disimpan dalam file `churn_scores.csv` yang memuat tiga kolom utama: `Customer_ID`, `ml_churn_score`, dan `ml_churn_label`.

Di sisi dashboard, file `churn_scores.csv` digabungkan (`merge/join`) dengan data pelanggan historis menggunakan `Customer_ID` sebagai kunci penghubung. Dengan cara ini, setiap baris data pelanggan di dashboard memiliki informasi probabilitas churn dan label risiko yang dihasilkan oleh model. Threshold yang digunakan untuk mengklasifikasikan label churn diambil dari `thresholds.json` agar konsisten dengan strategi evaluasi yang ditetapkan pada

proses training, yaitu min_precision dengan target precision 0,65 dan threshold final Stacking Ensemble sebesar 0,5153.

Perlu dicatat bahwa ml_churn_label pada churn_scores.csv saat ini menggunakan threshold default 0,5 dari fungsi predict bawaan model. Untuk konsistensi penuh dengan strategi bisnis, dashboard sebaiknya menerapkan threshold 0,5153 dari thresholds.json secara langsung saat membaca ml_churn_score, bukan mengandalkan ml_churn_label yang sudah tersimpan. Hal ini memastikan bahwa jumlah pelanggan yang ditampilkan sebagai "berisiko churn" di dashboard sesuai dengan keputusan threshold yang telah dievaluasi.

Rekomendasi Aksi Berdasarkan Tier Risiko

Dashboard tidak hanya berfungsi sebagai alat visualisasi, tetapi juga sebagai panduan aksi operasional yang dapat langsung digunakan oleh tim bisnis dan customer service. Berdasarkan distribusi churn score, rekomendasi aksi dibagi ke dalam empat tier sebagai berikut.

Pertama, pelanggan dengan churn score $\geq 0,80$ (very high-risk, sekitar 4.843 pelanggan) memerlukan intervensi personal dalam waktu 24 hingga 48 jam. Tindakan yang direkomendasikan mencakup follow-up telepon langsung oleh customer service, penawaran paket retensi eksklusif dengan diskon signifikan, atau evaluasi kualitas layanan jika pelanggan memiliki riwayat keluhan. Kelompok ini merupakan prioritas tertinggi karena probabilitas churnnya sangat kuat dan nilai pendapatannya bagi perusahaan paling berisiko hilang dalam waktu dekat.

Kedua, pelanggan dengan churn score antara 0,70 dan 0,79 (high-risk, sekitar 9.460 pelanggan) dapat ditangani melalui program retensi terstruktur seperti penawaran upgrade paket, pemberian loyalty reward, atau kampanye SMS/email yang dipersonalisasi berdasarkan pola penggunaan mereka. Intervensi untuk kelompok ini dapat dijadwalkan dalam rentang satu hingga dua minggu.

Ketiga, pelanggan dengan churn score antara 0,5153 dan 0,69 (medium-risk, sesuai threshold final) dapat dimasukkan ke dalam kampanye retensi digital massal seperti push notification,


email edukasi tentang fitur layanan, atau program referral. Pemantauan berkala melalui dashboard cukup dilakukan setiap minggu untuk melihat pergerakan skor risiko kelompok ini.

Keempat, pelanggan dengan churn score di bawah 0,5153 (low-risk) tidak memerlukan tindakan retensi aktif dalam jangka pendek. Kelompok ini cukup dimonitor melalui KPI dashboard dan diperlakukan dengan program loyalitas standar yang berlaku untuk seluruh pelanggan.


Dengan pendekatan berbasis tier risiko ini, perusahaan dapat mengalokasikan anggaran retensi secara proporsional sesuai dengan tingkat urgensi masing-masing kelompok pelanggan, sehingga efektivitas program retensi meningkat tanpa perlu menaikkan total anggaran secara keseluruhan.

Dokumentasi Dashboard

Gambar 7.1 Dashboard Tab Ringkasan Churn Pelanggan:



Gambar 7.2 Dashboard Tab Prediksi Churn Pelanggan:



Tautan Artefak Proyek

- Link GitHub proyek:
<https://github.com/dzakialthalsy/KBA-Telecommunication-Company-Churn-Analytic>
- Link Google Colab pengerjaan model:
https://colab.research.google.com/drive/1lW74w0GwIJEfZXaaRxCa9gsFgn_JqO_1?usp=sharing

Tabel 7.1 Komponen Dashboard dan Manfaatnya

Komponen Dashboard	Sumber Data	Manfaat
Total Churn Rate	Data pelanggan historis	Mengetahui tingkat churn pelanggan secara keseluruhan
Komposisi Segmen Pelanggan	Data pelanggan dan segmentasi	Melihat distribusi pelanggan berdasarkan kategori churn dan nilai pelanggan
Distribusi Risiko Churn	Data segmentasi risiko	Mengetahui jumlah pelanggan pada kategori risiko low, medium, dan high
Tren Churn Berdasarkan Lama Berlangganan	Data tenure/months	Mengidentifikasi pola churn berdasarkan durasi berlangganan
Potensi Pendapatan Hilang	Churn score dan data pendapatan	Mengukur dampak finansial dari pelanggan risiko tinggi
Total Pelanggan Risiko Tinggi	churn_scores.csv	Menentukan jumlah pelanggan prioritas retensi
Churn Label	ml_churn_label	Melihat proporsi pelanggan yang diprediksi churn dan tidak churn
Churn Score Berdasarkan Pendapatan	ml_churn_score dan avg revenue	Menganalisis hubungan risiko churn dengan pendapatan pelanggan

Dampak Customer Service Call	Data customer service dan churn score	Melihat hubungan interaksi layanan pelanggan terhadap risiko churn
------------------------------	---------------------------------------	--

Dengan adanya integrasi ini, insight dari model machine learning dapat digunakan secara lebih operasional. Hasil prediksi tidak hanya berhenti pada evaluasi model, tetapi diterjemahkan menjadi informasi visual yang mudah dipahami dan dapat digunakan untuk menentukan strategi retensi pelanggan secara lebih terarah.

8. Artefak Model dan Reproducibility

Notebook utama yang digunakan adalah [Gold_ML.ipynb](#). Artefak yang dihasilkan mencakup [preprocessor.joblib](#) untuk preprocessing, [selector.joblib](#) untuk feature selection, [stack_model.joblib](#) untuk model ensemble, [best_model.joblib](#) sebagai bundle model, [thresholds.json](#) untuk menyimpan threshold, dan [churn_scores.csv](#) untuk hasil prediksi seluruh pelanggan.

Penyimpanan artefak ini penting agar pipeline prediksi dapat direproduksi. Deployment atau dashboard tidak perlu membangun ulang preprocessing dari awal, melainkan cukup memuat bundle model dan menerapkan transformasi yang sama seperti saat training.

9. Kesimpulan

Proyek ini telah membangun pipeline machine learning yang sesuai dengan karakteristik masalah churn prediction. Teknik data mining yang digunakan relevan, preprocessing dilakukan secara mendalam, eksperimen model dilakukan secara sistematis, dan evaluasi model dikaitkan dengan kebutuhan bisnis retensi pelanggan.

Model Stacking Ensemble dipilih sebagai kandidat final karena memberikan performa agregat terbaik dari sisi accuracy, ROC-AUC, dan PR-AUC. Model ini digunakan untuk menghasilkan churn score sehingga perusahaan dapat memprioritaskan pelanggan berdasarkan tingkat risiko. Hasil analitik telah diintegrasikan ke dashboard melalui tab Ringkasan Churn Pelanggan dan Prediksi Churn Pelanggan, sehingga insight prediktif dapat digunakan untuk pengambilan keputusan retensi secara cepat dan terarah.