

P02-SIA: Penyiapan Repositori Data (DW/DL) Implementasi Medallion Architecture pada Proyek Telco Churn Analytics



Dosen Pengampu:

Ir. Nanang Yudi Setiawan, S.T., M.Kom

Disusun oleh:

- | | |
|-------------------------|-------------------|
| 1. Dzaki Althalsyah | (245150407111071) |
| 2. Dhea Akmalia Fibri | (245150407111081) |
| 3. Muhammad Rifa Aqilla | (245150407111047) |
| 4. Fairuz El Fauzy | (245150407111032) |

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
2026**

BAB I

PENDAHULUAN

1.1 Latar Belakang

Industri telekomunikasi merupakan sektor yang memiliki tingkat kompetisi tinggi, variasi layanan yang kompleks, serta ketergantungan besar terhadap loyalitas pelanggan. Dalam kondisi tersebut, perusahaan tidak cukup hanya mengumpulkan data transaksi dan perilaku pelanggan, tetapi juga harus mampu menyiapkan repositori data yang terstruktur agar data tersebut dapat diolah menjadi informasi strategis. Salah satu permasalahan utama yang relevan pada industri ini adalah churn pelanggan, yaitu kondisi ketika pelanggan berhenti menggunakan layanan dalam periode tertentu.

Dataset yang digunakan pada proyek ini berasal dari Kaggle, yaitu Telecom Customer Dataset, dengan skala sekitar 100.000 baris dan 100 kolom, serta target utama berupa kolom churn. Dataset ini memuat informasi yang cukup beragam, mulai dari pendapatan bulanan pelanggan, penggunaan menit telepon, kualitas panggilan, status perangkat, hingga atribut rumah tangga dan demografis. Variasi atribut tersebut menjadikan dataset ini cocok untuk studi kasus business intelligence dan analytics, namun sekaligus menimbulkan tantangan pada aspek kualitas data, konsistensi struktur, dan kebutuhan kurasi sebelum siap digunakan oleh pengguna bisnis.

Untuk menjawab kebutuhan tersebut, proyek ini menerapkan Medallion Architecture sebagai pendekatan penyiapan repositori data. Medallion Architecture membagi pengolahan data ke dalam tiga layer utama, yaitu Bronze, Silver, dan Gold, sehingga setiap tahap memiliki tanggung jawab yang jelas. Layer Bronze menangani data mentah, layer Silver menangani data hasil pembersihan dan standarisasi, sedangkan layer Gold menyajikan tabel akhir yang siap digunakan untuk analitik bisnis dan dashboard.

Pendekatan ini dipilih karena mampu memberikan beberapa keuntungan utama. Pertama, data lineage menjadi lebih jelas karena perubahan data dapat ditelusuri dari sumber mentah sampai tabel bisnis akhir. Kedua, proses debugging lebih mudah dilakukan karena setiap masalah kualitas data dapat diisolasi pada layer tertentu. Ketiga, repositori data menjadi lebih siap untuk dikembangkan lebih lanjut ke kebutuhan machine learning, dashboard BI, maupun evaluasi strategi retensi pelanggan.

1.2 Tujuan

Tujuan dari tugas ini adalah sebagai berikut:

1. Merancang repositori data berbasis Data Warehouse / Data Lakehouse sederhana untuk kasus churn pelanggan telekomunikasi.
2. Menerapkan Medallion Architecture secara eksplisit melalui layer Bronze, Silver, dan Gold.
3. Menyusun pipeline ETL/ELT yang logis dari proses ingestion hingga serving.
4. Menyajikan visualisasi arsitektur Model C4 untuk menjelaskan sistem secara kontekstual, struktural, dan komponen.

5. Memberikan justifikasi teknologi yang digunakan berdasarkan volume, variasi data, dan kebutuhan analitik proyek.
6. Menyusun laporan teknis yang profesional, lengkap, dan dilengkapi dengan kamus data singkat.

1.3 Ruang Lingkup

Ruang lingkup pekerjaan pada laporan ini meliputi:

1. Penjelasan arsitektur data yang digunakan untuk proyek Telco Churn Analytics.
2. Penjelasan implementasi layer Bronze, Silver, dan Gold pada repositori data.
3. Penjelasan alur ETL dari file CSV mentah hingga tabel siap konsumsi bisnis.
4. Penjelasan peran Docker, DuckDB, Python, dan Metabase dalam sistem.
5. Penyajian tiga jenis diagram arsitektur: System Context Diagram, Container Diagram, dan Component Diagram.
6. Penyusunan kamus data untuk kolom-kolom penting yang paling relevan dalam analisis churn.

Adapun ruang lingkup laporan ini tidak mencakup pembangunan dashboard final Metabase dan hasil model machine learning final, karena pada tahap penyusunan laporan ini sistem baru sampai pada repositori data, proses ETL, dan penyajian tabel siap analitik.

BAB II

IMPLEMENTASI MEDALLION ARCHITECTURE

2.1 Gambaran Umum Arsitektur

Repositori data pada proyek ini dirancang menggunakan pendekatan Medallion Architecture yang terdiri atas tiga layer utama, yaitu:

1. Bronze Layer untuk menyimpan data mentah hasil ingestion dari sumber.
2. Silver Layer untuk menyimpan data yang telah dibersihkan, dikurasi, dan distandarkan.
3. Gold Layer untuk menyimpan tabel bisnis final yang siap digunakan untuk dashboard dan analisis bisnis.

Pemisahan ini diterapkan secara eksplisit agar setiap layer memiliki fungsi yang berbeda dan tidak saling tumpang tindih. Dengan demikian, sistem tidak hanya memenuhi kebutuhan penyimpanan data, tetapi juga mendukung tata kelola data, konsistensi transformasi, dan kemudahan pemeliharaan pipeline.

2.2 Bronze Layer

Bronze Layer pada proyek ini direalisasikan dalam tabel `bronze_telecom_raw`. Layer ini berfungsi sebagai titik masuk data dari sumber eksternal, yaitu file CSV dataset pelanggan telekomunikasi. Prinsip utama pada Bronze adalah data disimpan apa adanya tanpa transformasi bisnis yang mengubah makna isi data. Dengan kata lain, Bronze berperan sebagai salinan mentah yang tetap dekat dengan sumber asli.

Pada saat ingestion ke Bronze, sistem hanya menambahkan metadata teknis untuk membantu pelacakan sumber data dan audit proses. Tiga metadata yang ditambahkan adalah:

1. `_ingested_at` untuk mencatat waktu ingestion.
2. `_source_file` untuk mencatat nama file CSV sumber.
3. `_row_id` untuk memberi nomor urut pada setiap baris data.

Aturan transformasi pada Bronze sangat jelas:

1. Data dibaca langsung dari CSV sumber.
2. Tidak ada penghapusan kolom bisnis.
3. Tidak ada imputasi missing value.
4. Tidak ada standarisasi tipe data bisnis.
5. Tidak ada agregasi.
6. Hanya dilakukan penambahan metadata ingestion.

Dengan aturan tersebut, Bronze menjadi dasar lineage yang kuat karena data dapat selalu ditelusuri kembali ke kondisi awal saat masuk ke sistem.

2.3 Silver Layer

Silver Layer direalisasikan dalam tabel `silver_telecom_cleaned`. Layer ini bertugas mengubah data mentah dari Bronze menjadi data yang lebih konsisten, bersih, dan siap dipakai untuk pembentukan tabel bisnis. Pada layer ini, seluruh proses kurasi dilakukan terhadap data hasil salinan Bronze, bukan terhadap file sumber asli, sehingga prinsip pemisahan tanggung jawab antar layer tetap terjaga.

Aturan transformasi pada Silver dirancang secara eksplisit dan berurutan sebagai berikut.

2.3.1 Penghapusan Metadata Bronze

Kolom metadata Bronze, yaitu `_ingested_at`, `_source_file`, dan `_row_id`, dihapus dari data analitik karena metadata tersebut tidak digunakan dalam analisis churn maupun agregasi bisnis.

2.3.2 Penghapusan Kolom Tidak Relevan

Sebanyak 11 kolom dihapus dari Silver karena memiliki tingkat missing value yang tinggi atau tidak relevan terhadap kebutuhan analitik churn pada tahap ini. Kolom yang dihapus adalah:

1. `numbcars`
2. `ownrent`
3. `dwlltype`
4. `dwllsize`
5. `HHstatin`
6. `lor`
7. `adults`
8. `income`
9. `infobase`
10. `hnd_webcap`
11. `prizm_social_one`

Langkah ini penting untuk mengurangi noise, memperkecil beban pemrosesan, dan menjaga agar tabel hasil kurasi tetap fokus pada atribut yang relevan untuk analitik churn.

2.3.3 Imputasi Missing Value

Penanganan missing value dilakukan secara sistematis berdasarkan karakteristik kolom:

1. Median imputation untuk kelompok metrik penggunaan dan pendapatan bulanan: `rev_Mean`, `mou_Mean`, `totmrc_Mean`, `da_Mean`, `ovrmou_Mean`, `ovrrev_Mean`, `vceovr_Mean`, `datovr_Mean`, `roam_Mean`.
2. Median imputation untuk perubahan perilaku pelanggan: `change_mou`, `change_rev`.
3. Median imputation untuk ringkasan enam bulan: `avg6mou`, `avg6qty`, `avg6rev`.
4. Median imputation untuk harga perangkat: `hnd_price`.
5. Fill dengan nilai "Unknown" untuk kolom kategorikal: `truck`, `rv`, `forgrntvl`, `ethnic`, `kid0_2`, `kid3_5`, `kid6_10`, `kid11_15`, `kid16_17`, `credited`, `marital`, `dualband`, `refurb_new`, `area`.
6. Median imputation untuk numerik skala kecil: `phones`, `models`, `eqpdays`.

Pemilihan median sebagai strategi utama dilakukan karena median lebih tahan terhadap outlier dibandingkan mean, sehingga lebih stabil untuk data telekomunikasi yang memiliki distribusi tidak selalu simetris.

2.3.4 Penghapusan Duplikasi

Setelah missing value ditangani, data diperiksa terhadap kemungkinan adanya baris duplikat. Jika ditemukan, baris duplikat dihapus agar satu observasi pelanggan tidak tercatat lebih dari satu kali secara tidak valid.

2.3.5 Koreksi Tipe Data

Beberapa kolom utama kemudian dikoreksi tipe datanya agar siap diproses pada layer Gold. Implementasi ini mencakup:

1. Konversi churn menjadi integer.
2. Konversi avgrev, change_rev, custcare_Mean, drop_vce_Mean, dan hnd_price menjadi numerik.

Langkah ini penting untuk memastikan operasi statistik, agregasi, dan segmentasi pada Gold tidak gagal akibat inkonsistensi tipe data.

2.3.6 Outlier Capping

Setelah data bersih secara dasar, Silver menerapkan outlier capping dengan metode IQR Winsorizing. Nilai numerik dibatasi pada rentang:

1. Batas bawah = $Q1 - 1.5 * IQR$
2. Batas atas = $Q3 + 1.5 * IQR$

Metode ini digunakan agar nilai ekstrem tidak mendistorsi agregasi bisnis pada layer Gold. Namun, beberapa kolom dikecualikan dari proses ini karena secara bisnis tidak tepat untuk dicap sebagai outlier, yaitu:

1. churn
2. Customer_ID
3. credited
4. asl_flag
5. new_cell
6. months
7. uniqlsubs
8. actvsubs
9. phones
10. models
11. totcalls

2.3.7 Validasi Kualitas Akhir

Sebagai tahap akhir pada Silver, sistem melakukan validasi jumlah null yang tersisa setelah seluruh proses kurasi selesai. Target kualitas pada implementasi ini adalah tidak ada nilai null

yang tersisa pada tabel Silver. Hasil akhir setelah cleaning adalah data dengan sekitar 89 kolom yang siap digunakan sebagai dasar pembentukan layer Gold.

Secara keseluruhan, Silver bukan hanya berfungsi sebagai tahap pembersihan, tetapi juga sebagai lapisan conformance yang memastikan data dari Bronze menjadi seragam, layak dianalisis, dan dapat diandalkan oleh lapisan bisnis.

2.4 Gold Layer

Gold Layer adalah lapisan akhir yang menyajikan data dalam bentuk tabel bisnis siap konsumsi. Pada proyek ini, Gold dibangun sepenuhnya dari Silver, sehingga tidak ada ketergantungan langsung terhadap Bronze maupun sumber CSV. Hal ini konsisten dengan prinsip Medallion bahwa data bisnis hanya boleh dibentuk dari data yang sudah bersih dan tervalidasi.

Gold Layer pada proyek ini terdiri atas tiga tabel utama.

2.4.1 Tabel gold_customer_segments

Tabel ini digunakan untuk segmentasi pelanggan. Segmentasi dilakukan berdasarkan kombinasi kondisi churn aktual, pendapatan rata-rata pelanggan, dan indikator risiko rule-based yang digunakan pipeline saat output model ML belum tersedia.

Kategori segmen yang dihasilkan adalah: Churned, At-Risk, Watch, High Value, dan Stable. Aturan segmentasi yang digunakan adalah:

1. Pelanggan dengan churn = 1 masuk ke segmen Churned.
2. Pelanggan dengan skor risiko $\geq 0,7$ masuk ke segmen At-Risk.
3. Pelanggan dengan skor risiko $\geq 0,4$ namun kurang dari 0,7 masuk ke segmen Watch.
4. Pelanggan dengan avgrev di atas kuartil ke-75 masuk ke segmen High Value.
5. Selain itu dikategorikan sebagai Stable.

2.4.2 Tabel gold_churn_risk

Tabel ini menyajikan skor risiko churn per pelanggan. Pada kondisi implementasi saat ini, sistem masih menggunakan rule-based fallback karena file hasil model machine learning belum tersedia. Oleh sebab itu:

1. ml_churn_score diisi menggunakan skor rule-based internal pipeline.
2. ml_churn_label diturunkan dari threshold skor risiko.
3. risk_level dibagi menjadi High, Medium, dan Low.

Aturan klasifikasi risiko adalah: score $\geq 0,7$ diklasifikasikan sebagai High; score $\geq 0,4$ dan $< 0,7$ sebagai Medium; score $< 0,4$ sebagai Low. Struktur ini dirancang agar tabel Gold tetap dapat digunakan meskipun modul ML final belum terintegrasi.

2.4.3 Tabel gold_churn_summary

Tabel ini berisi ringkasan KPI tingkat segmen dan tingkat keseluruhan. Selain satu baris agregat total dengan segment = 'ALL', tabel ini juga menyajikan ringkasan per segmen pelanggan. KPI utama yang disediakan adalah: total_customers, churned_customers, churn_rate, retention_rate, at_risk_customers, avg_revenue_arpu, dan avg_revenue_change.

Dengan demikian, Gold Layer berfungsi sebagai data mart utama yang siap dikonsumsi oleh Metabase maupun pengguna bisnis lain.

2.5 Ringkasan Implementasi Medallion

Implementasi Medallion pada proyek ini memenuhi pemisahan tanggung jawab antar layer secara jelas:

1. Bronze bertanggung jawab pada penyimpanan data mentah dan metadata ingestion.
2. Silver bertanggung jawab pada kurasi kualitas data dan standarisasi.
3. Gold bertanggung jawab pada penyajian tabel bisnis siap analitik.

Kejelasan aturan transformasi di setiap layer inilah yang menjadi fondasi utama repositori data proyek, sekaligus memenuhi prinsip Medallion Architecture secara eksplisit.

BAB III

LOGIKA DATA PIPELINE DAN ETL/ELT

3.1 Gambaran Umum Pipeline

Pipeline data pada proyek ini dirancang untuk memindahkan data dari sumber mentah hingga siap dikonsumsi oleh alat BI. Entry point pipeline berada pada modul `run_pipeline.py`, yang mengatur eksekusi berurutan dari Bronze, Silver, Gold, dan pembuatan salinan read-only untuk Metabase. Secara konseptual, alur pipeline adalah sebagai berikut:

1. File CSV mentah dibaca dari folder data sumber.
2. Data dimasukkan ke Bronze bersama metadata ingestion.
3. Data Bronze dikurasi pada Silver melalui cleaning dan quality handling.
4. Data Silver dikonsolidasikan ke dalam tabel Gold.
5. File warehouse utama disalin menjadi file read-only.
6. Metabase membaca file read-only untuk keperluan analitik.

3.2 Tahap Ingestion

Tahap awal pipeline adalah pengecekan keberadaan file CSV sumber. Jika file tidak ditemukan, pipeline dihentikan agar tidak menghasilkan layer yang kosong atau tidak valid. Langkah ini merupakan bentuk validasi input dasar yang penting dalam sistem ETL modern.

Setelah file tersedia, pipeline membuat direktori target DuckDB apabila belum ada. Baru setelah itu data di-load ke Bronze. Dengan pola ini, pipeline tidak hanya melakukan pemrosesan data, tetapi juga menjamin kesiapan environment eksekusi.

3.3 Tahap Kurasi Data

Tahap Silver merupakan inti dari kualitas pipeline karena pada tahap inilah data mentah dibersihkan dan dikonformasikan. Kurasi dilakukan melalui kombinasi:

1. Penghapusan kolom yang tidak relevan.
2. Imputasi missing value.
3. Penghapusan duplikasi.
4. Perbaikan tipe data.
5. Pengendalian outlier.
6. Validasi akhir kualitas data.

Pipeline tidak berhenti hanya pada proses pembersihan sederhana. Implementasi ini secara eksplisit menangani berbagai jenis data kotor, termasuk atribut numerik yang hilang, atribut kategorikal yang kosong, baris duplikat, serta nilai ekstrem yang berpotensi merusak agregasi bisnis. Hal ini menunjukkan bahwa proses Silver bukan hanya ETL teknis, melainkan juga proses kurasi data yang matang.

3.4 Tahap Konsolidasi Bisnis

Setelah data lulus kurasi pada Silver, pipeline berpindah ke Gold untuk membentuk data mart bisnis. Tabel segmentasi pelanggan, tabel risiko churn, dan tabel ringkasan KPI dibangun dari data Silver yang sudah terkendali kualitasnya. Pendekatan ini memastikan bahwa dashboard dan analisis bisnis tidak langsung bersentuhan dengan data mentah.

Selain itu, pipeline juga mendukung integrasi hasil scoring machine learning apabila file `churn_scores.csv` tersedia. Namun, karena output model final belum ada pada tahap ini, sistem secara otomatis menggunakan fallback rule-based agar pipeline tetap dapat menyajikan tabel risiko secara konsisten.

3.5 Tahap Serving

Salah satu keputusan teknis penting pada proyek ini adalah pembuatan file DuckDB read-only copy setelah pembentukan Gold selesai. Mekanisme ini memberikan dua manfaat utama:

1. Metabase dapat membaca data tanpa mengganggu file warehouse utama yang sedang digunakan ETL.
2. Risiko konflik akses baca-tulis dapat dikurangi.

Secara arsitektural, pendekatan ini menunjukkan bahwa pipeline tidak berhenti pada proses transformasi, tetapi juga memikirkan kebutuhan serving layer dan concurrency sederhana antara proses ETL dan konsumsi BI.

3.6 Evaluasi Kualitas Logika Pipeline

Berdasarkan implementasi yang ada, logika pipeline dapat dinilai sangat memadai untuk kebutuhan sistem analitik modern skala proyek ini, karena:

1. Alur data jelas dari ingestion hingga serving.
2. Penanganan data kotor dilakukan secara eksplisit.
3. Kualitas data diverifikasi pada Silver.
4. Konsolidasi data bisnis dipisahkan pada Gold.
5. Hasil Gold langsung dipersiapkan untuk konsumsi BI.

Dengan demikian, pipeline yang dibangun tidak hanya memenuhi kebutuhan teknis ETL dasar, tetapi juga memenuhi karakteristik repositori data analitik yang rapi dan dapat dipertanggungjawabkan.

BAB IV

VISUALISASI ARSITEKTUR MODEL C4

4.1 Pendekatan Visualisasi

Untuk mendokumentasikan sistem secara terstruktur, proyek ini menggunakan pendekatan Model C4 pada tiga level, yaitu:

1. System Context Diagram untuk menunjukkan aktor dan sistem eksternal yang berinteraksi dengan sistem.
2. Container Diagram untuk menunjukkan komponen penyusun utama pada level arsitektur aplikasi dan data.
3. Component Diagram untuk menunjukkan proses internal pada ETL Engine.

Pendekatan ini dipilih karena membantu menjelaskan sistem secara bertahap, mulai dari konteks umum hingga detail komponen pemrosesan.

4.2 System Context Diagram

System Context Diagram menunjukkan bahwa sistem Telco Churn Analytics DW/DL berada di antara sumber data mentah, tim teknis, dan pengguna bisnis. Dalam konteks ini:

1. Data Engineer bertugas menjalankan pipeline ETL.
2. Telecom Customer Dataset menjadi sumber data mentah.
3. Business Analyst / Executive User menjadi pengguna akhir insight.
4. Sistem bertindak sebagai repositori data yang mengubah data mentah menjadi insight yang siap dianalisis.

1.1 Gambar Context Diagram:




Diagram ini menegaskan batas sistem dan relasinya dengan aktor utama tanpa masuk ke detail teknis internal.

4.3 Container Diagram

Container Diagram menunjukkan pemisahan struktur internal sistem menjadi beberapa bagian utama:

1. ETL Pipeline sebagai mesin pengolahan data.
2. Bronze Layer sebagai penyimpanan data mentah.
3. Silver Layer sebagai penyimpanan data hasil kurasi.
4. Gold Layer sebagai penyimpanan tabel bisnis final.
5. Gold Read-only Copy sebagai file konsumsi BI.
6. Metabase Dashboard sebagai alat visualisasi data.

1.2 Gambar Container Diagram:




Diagram ini memperlihatkan bagaimana data mengalir dari CSV mentah ke Bronze, Silver, Gold, lalu disajikan ke Metabase. Visualisasi container memberikan gambaran jelas tentang pemisahan storage, processing, dan serving layer.

4.4 Component Diagram

Component Diagram menyoroti isi dari ETL Engine, yang terdiri atas:

1. Data Loader
2. Bronze Loader
3. Silver Cleaner
4. Gold Publisher
5. Data Writer

1.3 Gambar Component Diagram:




Diagram ini penting karena menunjukkan bahwa ETL bukan satu blok hitam, melainkan sekumpulan komponen dengan tanggung jawab spesifik. Silver Cleaner menangani kualitas data, Gold Publisher menangani pembentukan tabel bisnis, sedangkan Data Writer menyiapkan file read-only untuk serving ke Metabase.

4.5 Evaluasi Kesesuaian terhadap Model C4

Dokumentasi arsitektur pada proyek ini dapat dikatakan sesuai dengan pendekatan Model C4 karena:

1. Konteks sistem dijelaskan pada level aktor dan sistem eksternal.
2. Container utama dipetakan secara jelas.
3. Komponen internal ETL divisualisasikan pada level detail proses.
4. Alur data dan tanggung jawab masing-masing bagian dapat dipahami dengan mudah.

Dengan demikian, visualisasi arsitektur bukan sekadar diagram blok sederhana, tetapi sudah berfungsi sebagai dokumentasi teknis yang menjelaskan desain sistem secara sistematis.

BAB V

JUSTIFIKASI PEMILIHAN TEKNOLOGI

5.1 Python sebagai ETL Pipeline

Python dipilih sebagai bahasa utama pipeline ETL karena memiliki ekosistem pustaka data yang sangat kuat, terutama untuk kebutuhan manipulasi data, imputasi, validasi, dan integrasi lanjutan dengan machine learning. Library seperti Pandas, NumPy, dan scikit-learn memungkinkan proses cleaning dan quality handling dilakukan dengan fleksibel namun tetap efisien.

Untuk proyek dengan ukuran data sekitar 100.000 baris dan kompleksitas transformasi yang cukup kaya, Python sangat memadai. Selain itu, Python mempermudah kesinambungan antara tahap data engineering dan tahap machine learning karena format data dan lingkungan kerja dapat dijembatani dengan mudah.

5.2 DuckDB sebagai Data Warehouse

DuckDB dipilih sebagai mesin warehouse utama karena sesuai untuk kebutuhan analitik lokal berbasis file dengan performa query kolumnar yang tinggi. Dibandingkan harus menyiapkan server database penuh, DuckDB memberikan beberapa keuntungan:

1. Ringan dan mudah dijalankan secara lokal.
2. Tidak memerlukan server terpisah.
3. Efisien untuk query analitik.
4. Sangat cocok untuk skala dataset proyek ini.

Dengan volume data sekitar 100.000 baris, penggunaan DuckDB sangat sinkron dengan kebutuhan proyek karena mampu menyimpan seluruh layer Bronze, Silver, dan Gold dalam satu file warehouse yang mudah dipindahkan, dicadangkan, dan diintegrasikan dengan container.

5.3 Docker sebagai Sarana Reprodusibilitas

Docker dipilih untuk memastikan seluruh anggota tim dapat menjalankan sistem pada environment yang konsisten. Hal ini penting karena proyek dikerjakan secara kolaboratif dan berpotensi dijalankan pada sistem operasi atau konfigurasi lokal yang berbeda-beda. Dengan Docker:

1. Dependensi Python dapat dikunci.
2. Konfigurasi ETL menjadi konsisten.
3. Metabase dapat dijalankan dengan cara yang sama untuk seluruh anggota tim.
4. Proses build dan deployment lokal menjadi lebih mudah direproduksi.

Dalam konteks tugas ini, Docker juga membantu mendemonstrasikan bahwa repositori data tidak hanya dirancang secara konseptual, tetapi juga dapat dijalankan sebagai sistem yang dapat direplikasi.

5.4 Metabase sebagai Lapisan BI

Metabase dipilih karena merupakan platform BI open-source yang ringan, mudah digunakan, dan sesuai untuk kebutuhan dashboard analitik akademik maupun bisnis. Metabase memiliki antarmuka GUI yang intuitif, sehingga pengguna non-teknis seperti business analyst atau executive user dapat membaca data dan membuat visualisasi tanpa menulis query yang kompleks.

Integrasi Metabase dengan Gold layer dilakukan melalui file DuckDB read-only copy, yang menjadi keputusan desain penting. Dengan pendekatan ini:

1. Metabase hanya mengakses data yang sudah siap konsumsi.
2. Query pengguna bisnis tidak mengganggu proses ETL.
3. Alur dari pipeline ke serving layer tetap sederhana namun jelas.

5.5 Google Colab untuk Pengembangan Model ML

Google Colab dipilih sebagai lingkungan eksperimen model machine learning karena menyediakan kemudahan penggunaan, akses pustaka data science, serta kemampuan eksekusi tanpa membebani resource lokal. Meskipun hasil ML final belum terintegrasi penuh pada tahap laporan ini, pilihan Colab tetap relevan karena:

1. Mendukung kolaborasi.
2. Mempermudah eksperimen model.
3. Memisahkan beban training dari environment produksi ETL.
4. Memfasilitasi ekspor file scoring untuk diintegrasikan ke Gold.

5.6 Kesesuaian Stack dengan Kebutuhan Proyek

Secara keseluruhan, kombinasi Python + DuckDB + Docker + Metabase + Google Colab sangat selaras dengan kebutuhan proyek ini karena:

1. Volume data masih moderat dan cocok untuk warehouse file-based.
2. Variasi atribut data membutuhkan cleaning yang fleksibel.
3. Hasil akhir perlu langsung disajikan ke layer BI.
4. Sistem perlu mudah direproduksi oleh tim mahasiswa.
5. Arsitektur harus cukup sederhana untuk diimplementasikan, tetapi tetap representatif terhadap praktik sistem analitik modern.

Dengan demikian, pemilihan teknologi tidak bersifat generik, melainkan benar-benar mengikuti karakteristik data, kebutuhan transformasi, dan target pengguna sistem.

BAB VI

KAMUS DATA

6.1 Kamus Data Layer Bronze

Metadata Teknis

Nama Kolom	Tipe / Sifat	Deskripsi
`_ingested_at`	Timestamp	Waktu ketika data masuk ke Bronze layer
`_source_file`	Teks	Nama file CSV sumber yang di-ingest
`_row_id`	Integer	Nomor urut baris untuk pelacakan data mentah

6.2 Kamus Data Utama untuk Analisis Churn

Nama Kolom	Deskripsi
Customer_ID	Identitas unik pelanggan
churn	Indikator apakah pelanggan churn pada 31-60 hari setelah tanggal observasi
rev_Mean	Rata-rata pendapatan bulanan
mou_Mean	Rata-rata menit penggunaan bulanan
totmrc_Mean	Rata-rata total tagihan berulang bulanan
da_Mean	Rata-rata panggilan bantuan direktori
ovrmou_Mean	Rata-rata menit penggunaan overage
ovrrev_Mean	Rata-rata pendapatan dari overage
vceovr_Mean	Rata-rata pendapatan overage suara
datovr_Mean	Rata-rata pendapatan overage data
roam_Mean	Rata-rata panggilan roaming
change_mou	Perubahan persentase menit penggunaan bulanan dibanding rata-rata tiga bulan sebelumnya
change_rev	Perubahan persentase pendapatan bulanan dibanding rata-rata tiga bulan sebelumnya
drop_vce_Mean	Rata-rata panggilan suara gagal atau terputus
drop_dat_Mean	Rata-rata panggilan data gagal atau terputus
blck_vce_Mean	Rata-rata panggilan suara yang terblokir
blck_dat_Mean	Rata-rata panggilan data yang terblokir
unan_vce_Mean	Rata-rata panggilan suara yang tidak terjawab
unan_dat_Mean	Rata-rata panggilan data yang tidak terjawab
plcd_vce_Mean	Rata-rata panggilan suara yang dicoba dilakukan
plcd_dat_Mean	Rata-rata panggilan data yang dicoba dilakukan

recv_vce_Mean	Rata-rata panggilan suara yang diterima
comp_vce_Mean	Rata-rata panggilan suara yang selesai
comp_dat_Mean	Rata-rata panggilan data yang selesai
custcare_Mean	Rata-rata panggilan ke customer care
ccrndmou_Mean	Rata-rata menit customer care yang dibulatkan
cc_mou_Mean	Rata-rata menit customer care yang tidak dibulatkan
inonemin_Mean	Rata-rata panggilan masuk kurang dari satu menit
threeway_Mean	Rata-rata panggilan three-way
mou_cvce_Mean	Rata-rata menit penggunaan panggilan suara selesai
mou_cdat_Mean	Rata-rata menit penggunaan panggilan data selesai
mou_rvce_Mean	Rata-rata menit penggunaan panggilan suara diterima
peak_vce_Mean	Rata-rata panggilan suara peak time
peak_dat_Mean	Rata-rata panggilan data peak time
mou_peav_Mean	Rata-rata menit penggunaan panggilan suara peak
mou_pead_Mean	Rata-rata menit penggunaan panggilan data peak
opk_vce_Mean	Rata-rata panggilan suara off-peak
opk_dat_Mean	Rata-rata panggilan data off-peak
mou_opkv_Mean	Rata-rata menit penggunaan panggilan suara off-peak
mou_opkd_Mean	Rata-rata menit penggunaan panggilan data off-peak
drop_blk_Mean	Rata-rata total panggilan yang dropped atau blocked
attempt_Mean	Rata-rata total panggilan yang dicoba
complete_Mean	Rata-rata total panggilan yang selesai
callfwdv_Mean	Rata-rata panggilan call forwarding
callwait_Mean	Rata-rata panggilan call waiting
months	Jumlah bulan pelanggan telah berlangganan
uniqsubs	Jumlah subscriber unik dalam rumah tangga
actvsbs	Jumlah subscriber aktif dalam rumah tangga
new_cell	Indikator pengguna ponsel baru
crclscod	Kode kelas kredit pelanggan
asl_flag	Indikator account spending limit
totcalls	Total jumlah panggilan sepanjang umur pelanggan
totmou	Total menit penggunaan sepanjang umur pelanggan
totrev	Total pendapatan pelanggan
adjrev	Total pendapatan yang telah disesuaikan
adjmou	Total menit penggunaan yang telah disesuaikan
adjqty	Total jumlah panggilan yang telah disesuaikan
avgrev	Rata-rata pendapatan bulanan sepanjang umur pelanggan
avgmou	Rata-rata menit penggunaan bulanan sepanjang umur pelanggan

avgqty	Rata-rata jumlah panggilan bulanan sepanjang umur pelanggan
avg3mou	Rata-rata menit penggunaan tiga bulan terakhir
avg3qty	Rata-rata jumlah panggilan tiga bulan terakhir
avg3rev	Rata-rata pendapatan tiga bulan terakhir
avg6mou	Rata-rata menit penggunaan enam bulan terakhir
avg6qty	Rata-rata jumlah panggilan enam bulan terakhir
avg6rev	Rata-rata pendapatan enam bulan terakhir
area	Area geografis pelanggan
dualband	Indikator perangkat dualband
refurb_new	Status handset refurbished atau baru
hnd_price	Harga perangkat saat ini
phones	Jumlah handset yang pernah diterbitkan
models	Jumlah model handset yang pernah diterbitkan
truck	Indikator kepemilikan truk
rv	Indikator kepemilikan RV
marital	Status pernikahan
forgrntvl	Dummy variable perjalanan ke luar negeri
ethnic	Kode ringkas etnisitas
kid0_2	Indikator anak usia 0-2 tahun dalam rumah tangga
kid3_5	Indikator anak usia 3-5 tahun dalam rumah tangga
kid6_10	Indikator anak usia 6-10 tahun dalam rumah tangga
kid11_15	Indikator anak usia 11-15 tahun dalam rumah tangga
kid16_17	Indikator anak usia 16-17 tahun dalam rumah tangga
credited	Indikator kepemilikan kartu kredit
eqpdays	Umur perangkat saat ini dalam hari

6.3 Kamus Data Tabel Gold

Tabel gold_customer_segments

Nama Kolom	Deskripsi
Customer_ID	Identitas unik pelanggan
churn	Label churn aktual
avgrev	Rata-rata pendapatan bulanan pelanggan
change_rev	Perubahan pendapatan dibanding periode sebelumnya
custcare_Mean	Rata-rata panggilan ke customer care
drop_vce_Mean	Rata-rata panggilan suara gagal
customer_segment	Hasil segmentasi pelanggan
segment_updated_at	Waktu pembentukan segmen

Tabel gold_churn_risk

Nama Kolom	Deskripsi
Customer_ID	Identitas unik pelanggan
churn	Label churn aktual
avgrev	Rata-rata pendapatan bulanan pelanggan
change_rev	Perubahan pendapatan dibanding periode sebelumnya
custcare_Mean	Rata-rata panggilan ke customer care
ml_churn_score	Skor risiko churn (saat ini diisi oleh fallback rule-based)
ml_churn_label	Label biner hasil threshold skor risiko
risk_level	Kategori risiko: High, Medium, atau Low
risk_updated_at	Waktu pembaruan skor risiko

Tabel gold_churn_summary

Nama Kolom	Deskripsi
segment	Nama segmen pelanggan atau ALL untuk total
total_customers	Jumlah pelanggan dalam segmen
churned_customers	Jumlah pelanggan churn dalam segmen
churn_rate	Rasio pelanggan churn terhadap total pelanggan
retention_rate	Rasio pelanggan yang bertahan
at_risk_customers	Jumlah pelanggan dengan kategori risiko tinggi
avg_revenue_arpu	Rata-rata pendapatan pelanggan
avg_revenue_change	Rata-rata perubahan pendapatan

BAB VII

KESIMPULAN

Proyek Telco Churn Analytics berhasil merancang repositori data untuk kebutuhan business intelligence dan analytics dengan pendekatan Medallion Architecture yang jelas dan terstruktur. Implementasi Bronze, Silver, dan Gold tidak hanya muncul sebagai konsep, tetapi diwujudkan dengan pemisahan tanggung jawab yang tegas di setiap layer. Bronze bertindak sebagai penyimpanan data mentah, Silver menangani kurasi dan kualitas data, sedangkan Gold menyajikan tabel bisnis final untuk analisis churn dan retensi pelanggan.

Dari sisi pipeline, sistem telah menunjukkan alur yang logis dari ingestion hingga serving. Data mentah dari CSV tidak langsung digunakan untuk dashboard, tetapi melalui tahapan quality handling yang sistematis, termasuk penghapusan kolom tidak relevan, imputasi missing value, deduplikasi, koreksi tipe data, dan pengendalian outlier. Setelah itu, data dikonsolidasikan ke dalam tabel Gold dan diterbitkan kembali sebagai file read-only untuk kebutuhan Metabase. Pola ini menunjukkan bahwa sistem sudah merepresentasikan praktik repositori data analitik modern dalam skala proyek akademik.

Visualisasi arsitektur yang menggunakan tiga level Model C4 juga memperjelas rancangan sistem dari sisi konteks, container, dan component. Sementara itu, pemilihan teknologi berupa Python, DuckDB, Docker, Metabase, dan Google Colab menunjukkan kesesuaian yang baik antara kebutuhan proyek, volume data, dan target pengguna sistem.


Secara keseluruhan, proyek ini telah memenuhi tujuan utama penyiapan repositori data DW/DL untuk studi kasus churn pelanggan telekomunikasi. Arsitektur yang dibangun sudah cukup kuat untuk menjadi fondasi pengembangan lanjutan, baik pada sisi dashboard bisnis maupun integrasi model machine learning final.

LAMPIRAN


Lampiran A. Dokumentasi Visual Sistem

1. Repository GitHub


(<https://github.com/dzakialthalsy/KBA-Telecommunication-Company-Churn-Analytics>)




2. System Context Diagram



3. Container Diagram




4. Component Diagram



Lampiran B. Dokumentasi BI dan Data

1. Tabel pada Metabase



Lampiran C. Dokumentasi Eksekusi Pipeline

1. ETL Log

