

Nama Anggota Kelompok :

- Dhea Akmalia Fibri (245150407111081)
- Muhammad Rifa Aqilla (245150407111047)
- Dzaki Althalsyah (245150407111071)
- Fairuz El Fauzy (245150407111032)

Dataset: <https://www.kaggle.com/datasets/abhinav89/telecom-customer>

1. Tujuan Proyek (Project Objective)

- Mengubah data operasional mentah pelanggan telekomunikasi (penggunaan layanan, pendapatan, interaksi pelanggan, dan data demografis) menjadi wawasan bisnis yang dapat ditindaklanjuti untuk meningkatkan retensi pelanggan.
- Membangun dasbor interaktif yang mampu memantau KPI utama serta memberikan peringatan dini terhadap pelanggan yang berisiko berhenti berlangganan (churn).
- Membangun analisis prediktif menggunakan model klasifikasi untuk mengidentifikasi pelanggan yang berpotensi churn berdasarkan pola penggunaan layanan, perubahan pendapatan, frekuensi keluhan, dan variabel perilaku lainnya dari dataset.

2. Sasaran Pengguna (Target Audience)

- **Manajemen Eksekutif (VP/Direktur):** Memerlukan dasbor tingkat tinggi untuk memantau tren churn rate, pendapatan, dan tingkat retensi pelanggan secara keseluruhan.
- **Manager Operasional & Customer Relation:** Membutuhkan akses ke data detail pelanggan yang berisiko churn untuk melakukan langkah mitigasi (seperti pemberian promo, penawaran retensi, atau tindak lanjut proaktif).
- **Data Analyst / BI Analyst:** Membutuhkan akses data terperinci untuk melakukan analisis mendalam mengenai pola perilaku pelanggan serta eksplorasi dan evaluasi model prediktif.
- Ketiga kelompok pengguna tersebut menjadi dasar perancangan RBAC, yaitu pemetaan kebutuhan informasi ke level akses data yang berbeda antara pengguna eksekutif, operasional, dan analis.

3. Komponen Utama (Key Features/Components)

- **Data Warehouse Integration:** Menyatukan data dari sumber dataset CSV ke dalam satu repositori terpusat berbasis DuckDB dengan pendekatan Medallion Architecture, Implementasi warehouse menggunakan schema fisik yang terpisah, yaitu bronze, silver, dan gold, sehingga pemisahan layer dilakukan secara eksplisit pada level database dan bukan hanya melalui prefix nama tabel.
- **Automated Data Pipeline (ETL):** Proses pembersihan dan transformasi data secara otomatis agar siap dianalisis, termasuk penanganan missing values, outlier, dan feature engineering.
- **Model Prediktif Klasifikasi (Churn Prediction):** Pembangunan dan perbandingan lima model klasifikasi (LightGBM, CatBoost, XGBoost, Random Forest, dan Linear Regression) untuk memprediksi kemungkinan churn pelanggan. Model terbaik yang dipilih adalah ensemble dari LightGBM, CatBoost, dan XGBoost, dengan output berupa churn risk score per pelanggan.
- **Visualisasi & Dasbor:** Panel kontrol yang menyajikan KPI retensi, distribusi churn, dan segmentasi risiko pelanggan secara terjadwal.
- **Fitur Drill-Down:** Memungkinkan pengguna melihat detail profil pelanggan tertentu dari grafik ringkasan, termasuk skor risiko churn dan rekomendasi tindakan mitigasi.
- **Katalog Role & Restricted Views:** Sistem menyediakan katalog role pengguna dan view terbatas untuk mendukung Role-Based Access Control (RBAC), sehingga tiap kelompok pengguna hanya mengakses tingkat detail data yang sesuai dengan kebutuhan bisnisnya.

4. Metrik Utama (KPIs) yang Akan Dilacak

- **Churn Rate:** Rasio pelanggan yang berhenti berlangganan dalam periode tertentu.
- **Retention Rate:** Persentase pelanggan yang tetap aktif setiap bulannya.
- **Churn Risk Score:** Skor probabilitas churn per pelanggan yang dihasilkan dari model klasifikasi.
- **Average Revenue Per User (ARPU):** Rata-rata pendapatan bulanan per pelanggan aktif, dipantau dari variabel avgrev.
- **Revenue Change Rate:** Persentase perubahan pendapatan bulanan vs rata-rata tiga bulan sebelumnya (change_rev).
- **Customer Care Call Rate:** Rata-rata jumlah panggilan ke layanan pelanggan sebagai indikator ketidakpuasan (custcare_Mean).
- **Model Accuracy / AUC-ROC:** Metrik evaluasi performa model klasifikasi churn.

5. Kebutuhan Teknis (Technical Requirements)

- **Tools Visualisasi:** Metabase untuk visualisasi data dan pembuatan dasbor interaktif.
- **Penyimpanan Data:** DuckDB untuk mengelola dataset pelanggan beserta hasil output model, dengan pemisahan schema bronze, silver, dan gold agar struktur Medallion Architecture diterapkan secara eksplisit.
- **Katalog Metadata & Role:** PostgreSQL digunakan sebagai katalog metadata untuk menyimpan user dan role yang menjadi dasar implementasi RBAC pada layer serving.
- **Model Analitik & Machine Learning:** Python (scikit-learn) untuk membangun pipeline preprocessing, feature selection, dan model klasifikasi. Evaluasi menggunakan metrik Accuracy, Precision, Recall, F1-Score, dan AUC-ROC.
- **Containerisasi:** Docker digunakan untuk memastikan konsistensi environment pengembangan dan deployment pipeline ETL serta model prediktif di seluruh anggota tim.
- **Validasi Kode Otomatis:** Pipeline CI dijalankan melalui GitHub Actions pada setiap push dan pull_request, mencakup instalasi dependensi, proses linting menggunakan flake8, serta pengujian menggunakan pytest.
- **Arsitektur Data:** Medallion Architecture (Bronze → Silver → Gold) diterapkan pada pipeline data di atas DuckDB. Bronze Layer disimpan pada schema bronze dan memuat data mentah hasil ingestion dari CSV beserta metadata teknis. Silver Layer disimpan pada schema silver dan memuat data yang telah dibersihkan, distandarisasi, serta diperkaya dengan feature engineering. Gold Layer disimpan pada schema gold dan berisi tabel bisnis siap konsumsi oleh Metabase, yaitu gold.churn_risk, gold.customer_segments, dan gold.churn_summary.
- **Keamanan:** Pembatasan akses data sensitif pelanggan melalui Role-Based Access Control (RBAC). Role Executive hanya mengakses ringkasan KPI agregat, role Operational mengakses data pelanggan berisiko churn untuk mitigasi, dan role Analyst mengakses data detail untuk analisis mendalam serta evaluasi model.
- Implementasi RBAC pada proyek ini dilakukan melalui kombinasi katalog role di PostgreSQL dan Katalog Role & Access Rules. Dengan pendekatan ini, kontrol akses tidak hanya didefinisikan pada level kebutuhan bisnis, tetapi juga diterapkan langsung pada data yang dikonsumsi oleh pengguna.

6. Sukses Kriteria (Success Metrics)

- Proses pembaruan data otomatis (ETL) dari dataset selesai dalam waktu kurang dari 2 jam setiap harinya.
- Dasbor digunakan oleh jajaran manajer dan analis dengan tingkat penggunaan harian lebih dari 80%.
- Efisiensi waktu dalam mengidentifikasi pelanggan berisiko churn meningkat, mengurangi kebutuhan pelaporan manual hingga 90%.
- Model klasifikasi churn mencapai nilai AUC-ROC minimal 0,75 dan akurasi minimal 80% pada data uji.

7. Timeline Proyek (Milestone)

- **Minggu 1:** Analisis kebutuhan bisnis, identifikasi stakeholder, eksplorasi dataset (EDA), pemetaan variabel penting, serta penetapan KPI utama proyek.
- **Minggu 2:** Perancangan model data, finalisasi aturan ETL, feature engineering, pemilihan algoritma klasifikasi, serta penyusunan struktur dashboard berdasarkan kebutuhan pengguna.
- **Minggu 3:** Pembangunan data warehouse dan proses transformasi data (ETL) menggunakan Docker, pelatihan dan validasi model klasifikasi (Decision Tree, Random Forest, Logistic Regression), serta evaluasi performa model.
- **Minggu 4:** Integrasi output model prediktif ke dalam dashboard, pembuatan visualisasi KPI, validasi hasil analitik, simulasi UAT internal, serta penyusunan SOP dan user guide.
- **Minggu 5:** Penyempurnaan dashboard dan model berdasarkan feedback UAT, UAT final.

Perangkat Kelola Proyek:

- **GITHUB:** Untuk manajemen skrip pemrosesan data, kode ETL, notebook model prediktif, dan konfigurasi Docker.
- **SPREADSHEET:** Untuk monitoring progres tugas harian tim proyek.
- **GOOGLE DOCS:** Sebagai platform kolaborasi penyusunan dokumen PRD dan laporan akhir.